

Segmentation client par la méthode RFM

Apprentissage non supervisé appliqué à 541 909 transactions e-commerce

Joséphine et Loïc — Formation Data Analyst

Clustering K-means · Analyse en Composantes Principales · Dashboard Streamlit

RESTITUTION ORALE

Mieux connaître les clients pour mieux les activer

La problématique

GlobalShop Direct veut adapter ses actions marketing, mais ne dispose d'aucune catégorie client prédéfinie dans ses données de vente.

La question

Peut-on regrouper les clients en segments cohérents, sans connaître à l'avance leurs catégories ?

La réponse

L'apprentissage non supervisé : laisser un algorithme découvrir des groupes naturels dans le comportement d'achat.

5 étapes, de la donnée brute au segment client

Le projet s'appuie sur 541 909 transactions e-commerce brutes (jeu Online Retail, UCI). L'objectif : passer d'un historique d'achats désordonné à des groupes de clients clairement identifiés et actionnables par le marketing, sans aucune étiquette fournie au départ — c'est le principe même de l'apprentissage non supervisé.

01

Nettoyage

Annulations, valeurs manquantes et doublons retirés. 541 909 lignes brutes réduites à 392 692 transactions fiables.

02

Indicateurs RFM

Récence, Fréquence, Montant calculés pour chacun des 4 338 clients, puis transformés et standardisés.

03

Clustering K-means

10 valeurs de K testées (silhouette, stabilité, profils métier) ; K=4 retenu comme meilleur compromis.

04

PCA

Réduction des 3 variables RFM à 2 axes, pour vérifier visuellement la séparation des segments.

05

Nommage métier

Les 4 groupes statistiques sont traduits en profils compréhensibles : Champions, Fidèles, Occasionnels, À Risque.

4 règles appliquées à 541 909 transactions brutes

Les données brutes du site e-commerce contiennent des erreurs de saisie, des retours et des lignes incomplètes qui fausseraient les indicateurs RFM si elles n'étaient pas retirées avant tout calcul.

-  Clients non identifiés retirés — sans identifiant client, impossible de rattacher l'achat à un profil
-  Commandes annulées exclues (préfixe "C") — un achat annulé n'est pas un comportement d'achat réel
-  Quantités et prix non positifs supprimés — retours, erreurs de saisie ou lignes tests
-  Doublons exacts éliminés — évite de compter deux fois le même achat dans le Montant

Transactions retenues

392 692

Clients uniques identifiés

4 338

3 chiffres suffisent à décrire un client

R

Récence

Nombre de jours depuis le dernier achat. Plus c'est bas, mieux c'est.

F

Fréquence

Nombre de commandes distinctes passées. Plus c'est haut, mieux c'est.

M

Montant

Total dépensé en livres sterling. Plus c'est haut, mieux c'est.



Intérêt métier : ces 3 indicateurs se calculent pour n'importe quelle base transactionnelle, sans donnée démographique. Ils suffisent à repérer qui achète beaucoup, souvent et récemment — la base de toute segmentation marketing.

Pourquoi $K = 4$, malgré un meilleur score en $K = 2$?

K testé	Silhouette	Lecture métier
2	0,433	Meilleure séparation, mais 2 groupes trop larges pour agir
3	0,336	Plus détaillé, score proche de $K=4$
4	0,333	4 profils métier distincts et actionnables

Les variables RFM sont d'abord transformées en logarithme (pour réduire leur asymétrie) puis standardisées, afin qu'aucune ne domine les autres à cause de son échelle. L'inertie ne montre ensuite pas de coude net : la décision ne peut pas être automatique. Nous confrontons silhouette, effectifs par cluster et profils RFM pour $K=2$, $K=3$ et $K=4$.

Nombre de segments retenu

4

4 profils métier actionnables + stabilité confirmée (ARI moyen 0,96 sur 5 initialisations)

Voir les 4 segments en 2 dimensions

La PCA résume les 3 variables RFM en 2 axes, pour visualiser les clients sur un simple graphique à points — tout en conservant l'essentiel de l'information d'origine.

Axe 1

75,1 %

valeur client : oppose faible et forte activité
(Fréquence/Montant)

Axe 2

18,8 %

nuance liée à la Récence, le dernier achat

Interprétation : sur le graphique, les 4 segments forment des nuages de points nettement séparés le long de l'axe 1 — preuve visuelle que le clustering sépare bien les clients à forte valeur des clients peu actifs, et pas seulement sur le papier.

Variance totale expliquée

93,9 %

de l'information RFM d'origine conservée sur seulement 2 axes : la visualisation est fiable, peu d'information est perdue

INDICATEURS CLÉS

La base client en un coup d'œil

Avant de détailler chaque segment, ces 4 chiffres donnent une photographie de l'ensemble de la base client — ils sont calculés automatiquement dans la page « KPI » du dashboard Streamlit, à partir des 4 338 profils RFM.



Clients uniques

4 338

clients identifiés après nettoyage des 541 909 transactions brutes



Chiffre d'affaires total

£8,89 M

somme du Montant retenu sur l'ensemble de la période



Panier moyen par client

£2 049

CA total divisé par le nombre de clients uniques



Clients Champions

16,3 %

707 clients, déjà la cible marketing la plus rentable

RÉSULTATS

Quatre segments, quatre priorités d'action

Interprétation : le clustering révèle un déséquilibre fort entre segments. Les **Champions** (16,3 % des clients) génèrent à eux seuls **64,5 % du chiffre d'affaires** ; avec les Fidèles, ces deux segments pèsent **89 % du CA pour 44 % des clients**. À l'inverse, les 1 590 clients À Risque (37 % de la base) n'ont pas acheté depuis en moyenne 187 jours — un signal de désengagement à traiter en priorité.

Segment	Clients	Récence	Fréquence	Montant moyen	Action recommandée
Champions	707	12 j	13,8	£8 108	Programme VIP, accès prioritaire
Fidèles	1 185	67 j	4,2	£1 819	Cross-sell, upsell, parrainage
Occasionnels	856	20 j	2,0	£510	Relance personnalisée, offre de bienvenue
À Risque	1 590	187 j	1,3	£354	Campagne de réactivation ciblée

Un outil interactif pour l'équipe marketing



KPI & PCA

Indicateurs clés et visualisation 2D des segments, mis à jour automatiquement



Boxplots

Comparaison des distributions R, F, M par segment pour justifier les écarts



Simulateur

Saisie manuelle d'un profil RFM → segment assigné instantanément par le modèle entraîné

Réponse à la problématique métier

GlobalShop Direct n'avait aucune catégorie client prédéfinie. Sans connaître les clients à l'avance, le clustering K-means a fait émerger 4 profils statistiquement stables et interprétables, qui expliquent à eux seuls pourquoi 16 % des clients (les Champions) génèrent 65 % du chiffre d'affaires. L'équipe marketing dispose désormais, via le dashboard Streamlit, d'un outil autonome pour cibler chaque segment avec une action adaptée — et non plus un message unique envoyé à toute la base.